

Регрессия по функциональным данным через линейные функционалы

Кейс 4. Отчёт по исследовательской работе

Авторы: Марковский Артём Владиславович, Щербаков Артём Олегович

Группа: J3210

Аннотация

Рассматривается задача восстановления скалярного отклика $y \in \mathbb{R}$ по объекту, который описывается функцией $x(t)$, $t \in [a, b]$ (функциональные данные). Признаки строятся как значения линейных интегральных функционалов $L_{\varphi_k}(x) = \int_a^b x(t)\varphi_k(t) dt$, после чего задача сводится к линейной регрессии. Теоретической основой служат пространство $L_2[a, b]$, линейные ограниченные функционалы и теорема об их общем виде. На синтетических данных реализованы численное интегрирование, три системы функционалов (тригонометрический ортонормированный базис, средние по подотрезкам, полиномы), метод наименьших квадратов через нормальные уравнения, восстановление весовой функции $w(t)$, Ridge регуляризация и исследования зависимости качества от числа функционалов m , параметра λ , уровня шума и плотности сетки. Показано, что выбор системы функционалов определяет, какие характеристики функции улавливает модель, а регуляризация повышает устойчивость оценок (на тесте достигается $R^2 \approx 0,99$).

Содержание

1	Введение и постановка задачи	3
2	Теоретические основы	3
2.1	Пространство $L_2[a, b]$	3
2.2	Линейные ограниченные функционалы	3
2.3	Теорема об общем виде непрерывного линейного функционала	3
2.4	Ортонормированные системы и коэффициенты Фурье	4
3	Метод	4
3.1	Дискретизация и численное интегрирование	4
3.2	Метод наименьших квадратов и регуляризация	4
3.3	Системы функционалов	4
3.4	Аналитическая проверка свойств функционалов	4
3.5	Вывод формул МНК	6
3.6	Вывод формулы гребневой регуляризации	6
4	Результаты	6
4.1	Данные и численное интегрирование	6
4.2	Системы функционалов и матрица признаков	7
4.3	Оценка МНК и восстановление весовой функции	8
4.4	Сравнение систем функционалов	9
4.5	Число функционалов и регуляризация	10
4.6	Устойчивость к шуму и к изменению сетки	11
4.7	Кусочно-гладкие данные	11
5	Выводы	12
	Использование ИИ	12
	Список литературы	13
	Приложение. Репозиторий с кодом	13

1 Введение и постановка задачи

Во многих прикладных задачах объект наблюдения задаётся не конечным вектором признаков, а функцией одной переменной: суточная кривая температуры, сигнал ЭКГ, профиль нагрузки, спектр, временной ряд. Такие объекты называют *функциональными данными*.

Постановка. Каждому объекту i соответствует функция $x_i(t)$ на интервале $[a, b]$ и скалярный отклик $y_i \in \mathbb{R}$. Требуется построить отображение $x \mapsto \hat{y}(x)$. Числовые признаки извлекаем линейными интегральными функционалами

$$L_\varphi(x) = \int_a^b x(t) \varphi(t) dt,$$

где φ - весовая функция. Зафиксировав систему $\varphi_1, \dots, \varphi_m$, по каждой x_i строим вектор признаков $z_i = (z_{i,1}, \dots, z_{i,m})$, $z_{i,k} = L_{\varphi_k}(x_i) = \langle x_i, \varphi_k \rangle$, и переходим к линейной модели

$$\hat{y}_i = \beta_0 + \sum_{k=1}^m \beta_k z_{i,k}.$$

Цели работы: задать дискретизацию и численное интегрирование; выбрать и обосновать системы функционалов; вывести и реализовать МНК; восстановить весовую функцию $w(t)$; сравнить системы по MSE, RMSE, R^2 и по устойчивости коэффициентов; исследовать влияние m ; добавить Ridge регуляризацию; исследовать устойчивость к шуму и к изменению сетки.

2 Теоретические основы

Изложение опирается на учебник Колмогорова и Фомина «Элементы теории функций и функционального анализа» (далее - [КФ]).

2.1 Пространство $L_2[a, b]$

Рабочим пространством является $L_2[a, b]$ со скалярным произведением и нормой

$$\langle x, y \rangle = \int_a^b x(t) y(t) dt, \quad \|x\| = \sqrt{\langle x, x \rangle}.$$

Все признаки - это скалярные произведения $z_k = \langle x, \varphi_k \rangle$.

2.2 Линейные ограниченные функционалы

Функционал $L : L_2 \rightarrow \mathbb{R}$ линеен, если $L(\alpha x + \beta z) = \alpha L(x) + \beta L(z)$, и ограничен (для линейного функционала это равносильно непрерывности), если $|L(x)| \leq C\|x\|$. Для $L_\varphi(x) = \langle x, \varphi \rangle$ при $\varphi \in L_2[a, b]$ линейность следует из линейности интеграла, а ограниченность - из неравенства Коши-Буняковского $|L_\varphi(x)| = |\langle x, \varphi \rangle| \leq \|\varphi\| \|x\|$, причём равенство достигается на $x = c\varphi$, поэтому $\|L_\varphi\| = \|\varphi\|$.

2.3 Теорема об общем виде непрерывного линейного функционала

В гильбертовом пространстве всякий непрерывный линейный функционал f представим единственным образом как $f(x) = \langle x, w \rangle$, $\|f\| = \|w\|$. Агрегированный функционал модели $x \mapsto \sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle$ линеен, поэтому его представитель есть

$$w(t) = \sum_{k=1}^m \beta_k \varphi_k(t), \quad \hat{y}(x) = \beta_0 + \langle x, w \rangle. \quad (1)$$

Восстановление $w(t)$ даёт содержательную интерпретацию модели: w показывает, с каким весом значение $x(t)$ в точке t влияет на прогноз. Равенство (1) следует из линейности скалярного произведения по второму аргументу: $\sum_k \beta_k \langle x, \varphi_k \rangle = \langle x, \sum_k \beta_k \varphi_k \rangle$.

2.4 Ортонормированные системы и коэффициенты Фурье

Система $\{\varphi_k\}$ ортонормирована, если $\langle \varphi_k, \varphi_\ell \rangle = \delta_{k,\ell}$. Тогда $z_k = \langle x, \varphi_k \rangle$ - коэффициенты Фурье x , для которых $\sum_k z_k^2 \leq \|x\|^2$ (неравенство Бесселя), с равенством Парсеваля при полноте системы. Обратное соответствие даёт *теорема Рисса-Фишера*: если $\{e_n\}$ - ортонормированная система в гильбертовом H и $(c_n) \in \ell_2$, то существует $x \in H$ такой, что $x = \sum_{n=1}^{\infty} c_n e_n$. На отрезке $[0, 1]$ ортонормирована тригонометрическая система $1, \sqrt{2} \sin(2\pi kt), \sqrt{2} \cos(2\pi kt)$; при ортонормированной системе признаки z_k - это коэффициенты Фурье объекта x .

3 Метод

3.1 Дискретизация и численное интегрирование

Функции хранятся значениями $x_i(t_j)$ на равномерной сетке. Интегралы приближаем составной формулой трапеций

$$\int_a^b f(t) dt \approx \sum_{j=0}^{N-2} \frac{f(t_j) + f(t_{j+1})}{2} (t_{j+1} - t_j),$$

погрешность которой для гладких функций есть $O(N^{-2})$ (стандартная оценка погрешности квадратур).

3.2 Метод наименьших квадратов и регуляризация

С матрицей плана $X = [\mathbf{1} \ Z]$ модель $\hat{y} = X\beta$; минимизируя $Q(\beta) = \|y - X\beta\|^2$, из $\nabla_\beta Q = -2X^\top(y - X\beta) = 0$ получаем нормальные уравнения и решение

$$X^\top X \hat{\beta} = X^\top y, \quad \hat{\beta} = (X^\top X)^{-1} X^\top y.$$

Гребневая регрессия минимизирует $Q_\lambda(\beta) = \|y - X\beta\|^2 + \lambda \|\beta\|_2^2$, откуда $\hat{\beta}_\lambda = (X^\top X + \lambda I)^{-1} X^\top y$. Слагаемое λI сдвигает собственные значения $X^\top X$ на λ , улучшая обусловленность; свободный член не штрафует.

3.3 Системы функционалов

Рассматриваем три системы: (i) тригонометрический ортонормированный базис (измеряет амплитуды гармоник); (ii) средние по подотрезкам - нормированные индикаторы m равных подотрезков $[\tau_{k-1}, \tau_k]$,

$$\varphi_k(t) = \frac{\mathbf{1}\{t \in [\tau_{k-1}, \tau_k]\}}{\tau_k - \tau_{k-1}}, \quad L_{\varphi_k}(x) = \frac{1}{\tau_k - \tau_{k-1}} \int_{\tau_{k-1}}^{\tau_k} x(t) dt$$

(локальное среднее); (iii) полиномы $1, t, t^2, \dots$ после ортонормировки (моменты функции).

3.4 Аналитическая проверка свойств функционалов

Проверка линейности. Для произвольного функционала $L_{\varphi_k}(x) = \int_a^b x(t) \varphi_k(t) dt$ линейность вытекает из свойств определённого интеграла. Для любых функций $x_1(t), x_2(t)$ и произвольных

констант α, β :

$$L_{\varphi_k}(\alpha x_1 + \beta x_2) = \int_a^b (\alpha x_1(t) + \beta x_2(t)) \varphi_k(t) dt = \alpha \int_a^b x_1(t) \varphi_k(t) dt + \beta \int_a^b x_2(t) \varphi_k(t) dt = \alpha L_{\varphi_k}(x_1) + \beta L_{\varphi_k}(x_2).$$

Проверка ортонормированности. Рассмотрим тригонометрическую систему на отрезке $[0, 1]$: $1, \sqrt{2} \sin(2\pi kt), \sqrt{2} \cos(2\pi kt)$. Условие ортонормированности $\langle \varphi_k, \varphi_\ell \rangle = \delta_{k,\ell}$ выполняется. Вычислим скалярное произведение для функций 1 и $\sqrt{2} \sin(2\pi kt)$:

$$\langle 1, \sqrt{2} \sin(2\pi kt) \rangle = \int_0^1 \sqrt{2} \sin(2\pi kt) dt = -\frac{\sqrt{2}}{2\pi k} \cos(2\pi kt) \Big|_0^1 = -\frac{\sqrt{2}}{2\pi k} (1 - 1) = 0.$$

Проверим норму базисной функции $\sqrt{2} \sin(2\pi kt)$:

$$\langle \sqrt{2} \sin(2\pi kt), \sqrt{2} \sin(2\pi kt) \rangle = 2 \int_0^1 \sin^2(2\pi kt) dt = \int_0^1 (1 - \cos(4\pi kt)) dt = \left(t - \frac{\sin(4\pi kt)}{4\pi k} \right) \Big|_0^1 = 1 - 0 = 1.$$

Аналогичным образом выводится ортонормированность всех остальных комбинаций базисных функций.

Для системы средних по подотрезкам (нормированных индикаторов) отрезок $[0, 1]$ разбивается на m равных интервалов $\Delta_k = [\tau_{k-1}, \tau_k]$ длины $h = 1/m$. Базисные функции задаются как $\varphi_k(t) = \frac{1}{\sqrt{h}} \mathbb{1}\{t \in \Delta_k\} = \sqrt{m} \mathbb{1}\{t \in \Delta_k\}$. Проверим условия ортонормированности.

Если $k = \ell$, вычислим квадрат нормы функции:

$$\langle \varphi_k, \varphi_k \rangle = \int_0^1 (\sqrt{m} \mathbb{1}\{t \in \Delta_k\})^2 dt = m \int_{\tau_{k-1}}^{\tau_k} 1 dt = m(\tau_k - \tau_{k-1}) = m \cdot \frac{1}{m} = 1.$$

Если $k \neq \ell$, то интервалы Δ_k и Δ_ℓ не пересекаются во внутренних точках этих множеств. Следовательно, произведение их индикаторных функций равно нулю на отрезке $[0, 1]$:

$$\langle \varphi_k, \varphi_\ell \rangle = \int_0^1 m \mathbb{1}\{t \in \Delta_k\} \cdot \mathbb{1}\{t \in \Delta_\ell\} dt = 0.$$

Для системы полиномов стандартный базис $1, t, t^2, \dots$ не является ортогональным в $L_2[0, 1]$. Можно использовать ортонормированную систему многочленов Лежандра. Проверим свойства первых двух нормированных полиномов системы: $\varphi_0(t) = 1$ и $\varphi_1(t) = \sqrt{3}(2t - 1)$.

Вычислим их нормы и взаимное скалярное произведение:

$$\langle \varphi_0, \varphi_0 \rangle = \int_0^1 1^2 dt = 1,$$

$$\langle \varphi_0, \varphi_1 \rangle = \int_0^1 1 \cdot \sqrt{3}(2t - 1) dt = \sqrt{3}(t^2 - t) \Big|_0^1 = \sqrt{3}(1 - 1) = 0,$$

$$\langle \varphi_1, \varphi_1 \rangle = \int_0^1 3(2t - 1)^2 dt = 3 \int_0^1 (4t^2 - 4t + 1) dt = 3 \left(\frac{4}{3} t^3 - 2t^2 + t \right) \Big|_0^1 = 3 \left(\frac{4}{3} - 2 + 1 \right) = 1.$$

Аналогично можно проверить и для других комбинаций.

3.5 Вывод формул МНК

Прогноз модели записывается как $\hat{y} = X\beta$. Функционал ошибки МНК в векторно-матричном виде записывается так:

$$Q(\beta) = (y - X\beta)^\top (y - X\beta) = y^\top y - y^\top X\beta - (X\beta)^\top y + (X\beta)^\top (X\beta).$$

Поскольку $y^\top X\beta$ является скаляром, он равен своему транспонированному: $(y^\top X\beta)^\top = \beta^\top X^\top y$. Тогда функционал приводится к виду:

$$Q(\beta) = y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X\beta.$$

Для нахождения минимума возьмём градиент по вектору β и приравняем его к нулю:

$$\nabla_\beta Q(\beta) = -2X^\top y + 2X^\top X\beta = 0.$$

Из этого уравнения следуют нормальные уравнения:

$$X^\top X\hat{\beta} = X^\top y.$$

При условии, что матрица $X^\top X$ обратима, получаем формулу решения МНК:

$$\hat{\beta} = (X^\top X)^{-1} X^\top y.$$

3.6 Вывод формулы гребневой регуляризации

Для повышения устойчивости оценок в Ridge-регрессии к функционалу МНК добавляется штраф за L_2 -норму векторов коэффициентов:

$$Q_\lambda(\beta) = (y - X\beta)^\top (y - X\beta) + \lambda \|\beta\|_2^2 = y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X\beta + \lambda \beta^\top \beta.$$

Вычислим градиент по β и приравняем к нулю:

$$\nabla_\beta Q_\lambda(\beta) = -2X^\top y + 2X^\top X\beta + 2\lambda\beta = -2X^\top y + 2(X^\top X + \lambda I)\beta = 0.$$

Отсюда получаем нормальные уравнения:

$$(X^\top X + \lambda I)\hat{\beta}_\lambda = X^\top y.$$

Добавление λI сдвигает собственные значения матрицы на λ , поэтому при $\lambda > 0$ матрица $(X^\top X + \lambda I)$ имеет строго положительные собственные значения и всегда обратима. Решение имеет вид:

$$\hat{\beta}_\lambda = (X^\top X + \lambda I)^{-1} X^\top y.$$

4 Результаты

Эксперименты проведены на синтетических данных $x_i(t) = a_i \sin 2\pi t + b_i \cos 2\pi t + c_i t + \varepsilon_i(t)$ с откликом $y_i = \langle x_i, w^* \rangle + \eta_i$, $w^*(t) = 2 \sin 2\pi t - t$; выборка из 400 объектов разбита на обучающую (300) и тестовую (100).

4.1 Данные и численное интегрирование

Примеры порождённых функций показаны на рис. 1. Корректность интегрирования подтверждена на непериодической функции с известным интегралом $\int_0^1 e^t dt = e - 1$: погрешность убывает как $O(N^{-2})$ (рис. 2). Это согласуется с теорией квадратур: локальная ошибка на каждом отрезке есть $O(h^3)$, число отрезков $\sim N$, поэтому суммарная погрешность $\sim N \cdot O(h^3) =$

$O(h^2) = O(N^{-2})$. Значит, на разумной сетке признаки $z_{i,k}$ вычисляются точно, и дискретизация не вносит заметной ошибки.




Рис. 1. Шесть случайных функций-наблюдений $x_i(t)$.




Рис. 2. Погрешность формулы трапеций убывает как $O(N^{-2})$.

4.2 Системы функционалов и матрица признаков

Линейность функционалов проверена численно: невязка $|L(\alpha x_1 + \beta x_2) - \alpha L(x_1) - \beta L(x_2)|$ порядка 10^{-16} (машинный нуль). Ортонормированность тригонометрической системы подтверждена матрицей Грама, практически совпадающей с единичной (рис. 3; максимальное отклонение $\sim 10^{-16}$). Первые строки матрицы признаков Z для тригонометрической системы ($m = 9$) приведены в табл. 1: видно, что основной вклад дают первые гармоники, а коэффициенты высоких частот близки к нулю - это согласуется со структурой порождающей модели.




Рис. 3. Матрица Грама тригонометрической системы практически единична: система ортонормирована в $L_2[a, b]$.

Таблица 1. Первые строки матрицы признаков Z (тригонометрическая система, $m = 9$).

1	$\sqrt{2} \sin(t)$	$\sqrt{2} \cos(t)$	$\sqrt{2} \sin(2t)$	$\sqrt{2} \cos(2t)$	$\sqrt{2} \sin(3t)$	$\sqrt{2} \cos(3t)$	$\sqrt{2} \sin(4t)$	$\sqrt{2} \cos(4t)$
-1.463	0.554	-0.706	0.328	-0.001	0.222	-0.004	0.163	-0.002
1.126	0.185	-0.726	-0.254	0.000	-0.164	0.001	-0.127	-0.001
-0.800	1.842	-0.933	0.177	0.006	0.120	0.004	0.086	0.003
-0.576	1.490	-0.723	0.127	-0.004	0.085	-0.005	0.065	-0.002
-0.050	0.180	0.931	0.010	0.001	0.003	-0.001	0.005	-0.000

4.3 Оценка МНК и восстановление весовой функции

Оценка через нормальные уравнения совпала с `numpy.linalg.lstsq` (расхождение в пределах машинной точности), что подтверждает корректность реализации. Модель даёт RMSE 0,103 на обучении и 0,110 на тесте при $R^2 \approx 0,994$ - ошибка на уровне шума отклика. Это ожидаемо: отклик по построению - линейный функционал от x . Восстановленная весовая функция (рис. 4) сравнивается с известной w^* : тригонометрическая система точно ловит синусоидальную часть, тогда как линейный тренд $-t$ требует многих гармоник, отчего виден эффект Гиббса; система средних по подотрезкам даёт ступенчатое (кусочно-постоянное) приближение. Выбор системы функционалов определяет, *какие* свойства функции «видит» модель.




Рис. 4. Восстановление весовой функции $w(t)$ (представителя Рисса) для трёх систем в сравнении с истинной $w^*(t) = 2\sin 2\pi t - t$.

4.4 Сравнение систем функционалов

Все три системы при $m = 9$ достигают высокого R^2 на тесте (табл. 2), но различаются устойчивостью оценок. По бутстрэп-оценке стандартного отклонения коэффициентов (рис. 5) наиболее устойчивы коэффициенты системы средних по подотрезкам, тогда как у тригонометрии и полиномов разброс выше: порождающие данные слабо возбуждают высокочастотные и высокостепенные признаки, поэтому соответствующие коэффициенты определяются менее точно.

Таблица 2. Сравнение систем функционалов по качеству прогноза.

система ($m = 9$)	MSE	RMSE	R^2
тригонометрия	0.012	0.110	0.994
средние по подотрезкам	0.012	0.111	0.993
полиномы (ортонорм.)	0.012	0.111	0.993




Рис. 5. Стандартное отклонение оценок коэффициентов (бутстрэп): наиболее устойчивы коэффициенты средних по подотрезкам.

4.5 Число функционалов и регуляризация

На малой обучающей выборке ($n = 40$) ошибка на обучении с ростом m падает почти до нуля, а на тесте после некоторого порога растёт - проявляется переобучение (рис. 6). Причина - баланс смещение/разброс: при малом числе объектов и большом m лишние коэффициенты подстраиваются под шум обучающей выборки, разброс оценки растёт, и прогноз на тесте ухудшается. Гребневая регуляризация при избыточном $m = 15$ снижает тестовую ошибку (с 0,110 у МНК до 0,109 при $\lambda \approx 1,4$) и уменьшает норму коэффициентов (рис. 7): усадка оценок стабилизирует модель ценой небольшого смещения.




Рис. 6. Зависимость RMSE от числа функционалов m (обучающая выборка $n = 40$): на тесте при больших m видно переобучение.




Рис. 7. Слева: RMSE на тесте от λ (умеренная регуляризация полезна при $m = 15$). Справа: норма коэффициентов убывает с ростом λ .

4.6 Устойчивость к шуму и к изменению сетки

Тестовая ошибка растёт примерно линейно с уровнем шума отклика (рис. 8, слева). К плотности сетки метод устойчив: ошибка остаётся у шумового порога ($\approx 0,10$) при всех N от 16 до 512 (справа), поскольку интегралы от гладких периодических компонент точно вычисляются даже на грубой сетке.




Рис. 8. Устойчивость: слева - к шуму отклика (линейный рост); справа - к плотности сетки (ошибка у шумового порога при всех N).

4.7 Кусочно-гладкие данные

Чтобы проверить зависимость выбора системы от структуры данных, сгенерированы кусочно-постоянные функции (вариант данных №2 из условия): x_i принимает случайные уровни на трёх равных сегментах, а отклик - линейная комбинация средних по сегментам. Все три системы предсказывают y у шумового порога (RMSE на тесте от 0,113 до 0,114), однако восстановление весовой функции различается (рис. 9): согласованная система средних ($m = 3$) воспроизводит ступенчатую w^* точно, тогда как тригонометрия даёт осцилляции Гиббса у точек разрыва.

Предсказательное качество совпадает, а интерпретируемость восстановленной w зависит от соответствия системы структуре данных.




Рис. 9. Кусочно-гладкие данные. Слева: примеры наблюдений. Справа: система средних восстанавливает ступенчатую w^* точно, тригонометрия - с эффектом Гиббса.

5 Выводы

1. Задача регрессии по функциональным данным корректно сводится к линейной модели над признаками $z_{i,k} = \langle x_i, \varphi_k \rangle$; теоретический каркас - $L_2[a, b]$, ограниченность интегральных функционалов и теорема Рисса об их общем виде. На тесте достигается $R^2 \approx 0,99$.
2. Весовая функция $w(t) = \sum_k \beta_k \varphi_k(t)$ - представитель Рисса агрегированного функционала; её восстановление даёт содержательную интерпретацию модели: разные системы улавливают разные свойства функции.
3. Устойчивость оценок зависит от того, насколько данные возбуждают признаки: наиболее устойчивы коэффициенты системы средних по подотрезкам (рис. 5), так как все их признаки имеют сопоставимую дисперсию.
4. Число функционалов и регуляризация управляют балансом смещение/разброс; гребневая регрессия повышает устойчивость при избыточном m .
5. Метод устойчив к умеренному шуму и к разумному измельчению сетки.

Использование ИИ

Содержательное решение (постановка, вывод формул, реализация, интерпретация, выводы) выполнено самостоятельно. ИИ применялся для разъяснения теории по учебнику Колмогорова-Фомина, оформления (LaTeX, докстринги) и проверки технических вычислений. Ссылки на чаты:

Ссылка на чат	Что сделано с помощью ИИ
ссылка	написание докстрингов для функций
ссылка	написание формул LaTeX
ссылка	неравенство Бесселя / Парсеваля (разд. 2.4)
ссылка	написание кода для сохранения графиков и таблиц в формате LaTeX

Список литературы

1. А. Н. Колмогоров, С. В. Фомин. *Элементы теории функций и функционального анализа*. - М.: Наука.

Приложение. Репозиторий с кодом

Исходный код (Python-модули, воспроизводящие все вычисления, графики и таблицы) выложен в репозитории: *(вставить ссылку на репозиторий)*.