

Метрические методы регрессии: ядерное сглаживание и LOWESS

Кейс 6. Отчёт по исследовательской работе

Авторы: Марковский Артём Владиславович, Щербаков Артём Олегович

Группа: J3210

Аннотация

Исследуются непараметрические метрические методы регрессии на основе ядерного сглаживания. Реализованы «с нуля» оценка Надарая-Ватсона с фиксированным и переменным окном, а также робастная схема LOWESS с итеративным перевзвешиванием объектов по остаткам. Параметры (ширина окна h , число соседей k , ядро K) подбираются по скользящему контролю (LOO). Теоретической основой служат понятие метрического пространства и гипотеза непрерывности. На синтетической задаче $y = \sin x + \varepsilon$ и двух реальных датасетах (Diabetes, California Housing) изучено влияние ядра, ширины окна и уровня загрязнения данных выбросами. Показано, что ширина окна влияет на качество сильнее выбора ядра, переменное окно выигрывает при неоднородной плотности данных, а LOWESS превосходит обычное сглаживание начиная с умеренной доли выбросов.

Содержание

1	Введение и постановка задачи	3
2	Теоретические основы	3
2.1	Метрическое пространство	3
2.2	Гипотеза непрерывности	3
2.3	Надарая-Ватсон как локально взвешенный МНК	3
2.4	Эквивалентные метрики и масштаб признаков	4
3	Метод	4
3.1	Ядра	4
3.2	Подбор параметров (LOO) и LOWESS	4
4	Результаты	4
4.1	Ширина окна и подбор параметров	5
4.2	Сравнение ядер	6
4.3	Выбросы и робастность LOWESS	7
4.4	Переменное окно и сопоставление факторов	8
4.5	Реальные данные	9
4.6	Подбор окна: LOO и кросс-валидация	10
4.7	Проверка: НВ как минимум локально взвешенного МНК	10
5	Выводы	11
	Использование ИИ	11
	Список литературы	12
	Приложение. Репозиторий с кодом	12

1 Введение и постановка задачи

Дана обучающая выборка $X^\ell = \{(x_i, y_i)\}_{i=1}^\ell$, $x_i \in \mathbb{R}^n$, $y_i \in \mathbb{R}$. Предполагается *гипотеза непрерывности*: близким объектам (в смысле метрики ρ) соответствуют близкие ответы. Требуется по объекту x оценить значение регрессии.

Обозначим ядерные веса $r_i = \rho(x, x_i)/h$. **Оценка Надарая-Ватсона** с фиксированным окном:

$$a(x; X^\ell, h) = \frac{\sum_{i=1}^\ell y_i K(r_i)}{\sum_{i=1}^\ell K(r_i)}, \quad r_i = \frac{\rho(x, x_i)}{h},$$

где $K(r)$ - ядро (невозрастающая весовая функция), $h > 0$ - ширина окна. **Переменное окно** задаётся $(k+1)$ -м соседом: $h(x) = \rho(x, x_{(k+1)})$; обозначив $\tilde{r}_i = \rho(x, x_i)/h(x)$,

$$a(x; X^\ell, k) = \frac{\sum_{i=1}^\ell y_i K(\tilde{r}_i)}{\sum_{i=1}^\ell K(\tilde{r}_i)}.$$

Для борьбы с выбросами рассматривается **робастная схема LOWESS**: по текущим весам γ_j вычисляются LOO-оценки a_i , затем веса обновляются по остатку $\varepsilon_i = |a_i - y_i|$: $\tilde{K}$: $\gamma_i = K(\varepsilon_i/(6 \text{ med}\{\varepsilon_j\}))$.

Цели: реализовать три метода с нуля; подобрать h, k, K по LOO; сравнить не менее трёх ядер; построить графики на синтетике; оценить качество на реальных данных по MAE, RMSE, R^2 ; добавить выбросы и сравнить НВ и LOWESS; исследовать, что важнее - ядро или ширина окна, когда выигрывает переменное окно и при каком уровне загрязнения выигрывает LOWESS.

2 Теоретические основы

Изложение опирается на учебник Колмогорова и Фомина (далее - [КФ]), раздел о метрических пространствах.

2.1 Метрическое пространство

Метрическое пространство - пара (M, ρ) , где $\rho : M \times M \rightarrow \mathbb{R}$ удовлетворяет аксиомам:

$$(1) \rho(x, y) \geq 0, \rho(x, y) = 0 \Leftrightarrow x = y; \quad (2) \rho(x, y) = \rho(y, x); \quad (3) \rho(x, z) \leq \rho(x, y) + \rho(y, z).$$

В $\mathbb{R}^n$ используем евклидову метрику $\rho(x, y) = \|x - y\|_2$. Именно неравенство треугольника (3) делает осмысленной транзитивность близости, на которой держится гипотеза непрерывности.

2.2 Гипотеза непрерывности

Гипотеза непрерывности - требование непрерывности искомой зависимости $f(x) = \mathbb{E}[y | x]$ как отображения метрических пространств: малое изменение x по метрике ρ влечёт малое изменение ответа. Ядро $K(\rho(x, x_i)/h)$ присваивает объектам вес, убывающий с расстоянием.

2.3 Надарая-Ватсон как локально взвешенный МНК

Оценка НВ получается как решение задачи локально взвешенного МНК при локальной модели-константе $f(x_i) \equiv \theta$:

$$Q(\theta; x) = \sum_{i=1}^\ell K\left(\frac{\rho(x, x_i)}{h}\right) (\theta - y_i)^2 \rightarrow \min_{\theta}.$$

Дифференцируя по θ и приравнивая нулю, получаем (вывод выполнен самостоятельно)

$$\frac{\partial Q}{\partial \theta} = 2 \sum_{i=1}^{\ell} K_i(\theta - y_i) = 0 \Rightarrow \theta^* = \frac{\sum_i K_i y_i}{\sum_i K_i} = a(x; X^\ell, h), \quad K_i := K\left(\frac{\rho(x, x_i)}{h}\right),$$

то есть оценка НВ - взвешенное среднее ответов с ядерными весами.

2.4 Эквивалентные метрики и масштаб признаков

Две метрики эквивалентны, если порождают одну топологию (достаточно $c_1 \rho_1 \leq \rho_2 \leq c_2 \rho_1$): тогда они задают одинаковую сходимость, но разные числовые значения расстояний. Поэтому при признаках разного масштаба евклидово расстояние определяется в основном «крупным» признаком, веса $K(\rho/h)$ искажаются, и необходима *стандартизация* признаков.

3 Метод

3.1 Ядра

Сравниваем четыре ядра (нормировочные множители опускаем - в отношении НВ они сокращаются), $(u)_+ = \max(0, u)$, $r = \rho/h \geq 0$:

$$K_{\text{гаусс}}(r) = e^{-r^2/2}, \quad K_{\text{Епанечн.}}(r) = (1 - r^2)_+, \quad K_{\text{квадр.}}(r) = (1 - r^2)_+^2, \quad K_{\text{треуг.}}(r) = (1 - r)_+.$$

Гауссовское ядро имеет неограниченный носитель; остальные три финитны (зануляются при $r \geq 1$). Все ядра невозрастающие, поэтому вес монотонно убывает с расстоянием.

3.2 Подбор параметров (LOO) и LOWESS

Качество параметров оцениваем по leave-one-out: прогноз для каждого объекта строится без него самого, затем берётся RMSE по всем объектам. В схеме LOWESS, стартуя с $\gamma_i \equiv 1$, на каждой итерации считаются LOO-оценки a_i , остатки $\varepsilon_i = |a_i - y_i|$ и их медиана, после чего веса обновляются бивесом Тьюки $\gamma_i = (1 - (\varepsilon_i / (6 \text{ med}\{\varepsilon\}))^2)_+^2$. Объекты-выбросы получают малый вес и почти не влияют на сглаживание.

4 Результаты

Синтетическая одномерная задача: x равномерно на $[0, 4\pi]$, $y = \sin x + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 0.3^2)$ (рис. 1).




Рис. 1. Истинная функция $f(x) = \sin x$ и зашумлённые наблюдения.

4.1 Ширина окна и подбор параметров

Влияние h показано на рис. 2: малое h даёт недосглаживание, большое - пересглаживание, промежуточное восстанавливает $\sin x$. Это баланс смещение/разброс: при малом h в окно попадает мало объектов и оценка повторяет шум (большой разброс), при большом h усредняется слишком широкая окрестность и пики срезаются (большое смещение). Поэтому LOO-ошибка U-образна (рис. 3) с чёткими оптимумами $h^* \approx 0,31$ и $k^* = 6$; в минимуме она выходит на уровень шума ($\text{RMSE} \approx 0,30$), что и ожидается при $\sigma = 0,3$.




Рис. 2. Влияние ширины окна h : недо- и пересглаживание (ядро Гаусса).




Рис. 3. LOO-ошибка от h (фикс. окно) и от числа соседей k (перем. окно).

4.2 Сравнение ядер

Для каждого ядра подобрано своё h^* (табл. 1). Минимальные LOO-ошибки четырёх ядер различаются лишь в третьем знаке, а кривые прогноза при оптимальном h практически совпадают (рис. 4). Причина: все ядра задают веса, монотонно убывающие с расстоянием, поэтому при оптимально подобранном h результат определяется эффективной шириной окна, а форма ядра - это эффект второго порядка.

Таблица 1. Сравнение ядер на синтетике (оптимальное h по LOO).

ядро	h^*	LOO RMSE
треугольное	0.604	0.304
Епанечникова	0.604	0.305
квадратичное	0.679	0.305
гауссовское	0.305	0.305




Рис. 4. Прогноз при разных ядрах (каждое со своим h^*) - кривые почти совпадают.

4.3 Выбросы и робастность LOWESS

В данные добавлены 12 % грубых выбросов. Обычная оценка НВ взвешивает объекты только по расстоянию, поэтому выброс, попавший в окно, тянет локальное среднее к себе; LOWESS дополнительно делит вес на величину остатка и подавляет выбросы (рис. 5): RMSE к истинной f падает с 0,337 (НВ) до 0,096 (LOWESS). На рис. 6 видно почему: после стабилизации выбросы получают веса γ_i , близкие к нулю, а их остатки больше, чем у обычных объектов.




Рис. 5. Обычное сглаживание против LOWESS при выбросах.




Рис. 6. Слева: веса γ_i после стабилизации LOWESS. Справа: распределение остатков $|a_i - y_i|$.

Зависимость качества от доли загрязнения (рис. 7): ошибка обычной НВ растёт почти линейно, так как каждый выброс смещает локальное среднее пропорционально своей величине; LOWESS же отсекает выбросы, и его ошибка держится у шумового порога. Поэтому LOWESS выигрывает уже с нескольких процентов загрязнения.




Рис. 7. Загрязнение данных: RMSE НВ и LOWESS в зависимости от доли выбросов.

4.4 Переменное окно и сопоставление факторов

При неоднородной плотности данных переменное окно адаптирует ширину к локальной плотности и даёт меньшую LOO-ошибку (0,310 против 0,316 у фиксированного, рис. 8). Прямое сопоставление факторов (рис. 9) количественно подтверждает главный вывод: размах LOO-ошибки при варьировании ширины окна (0,393) на порядок больше, чем при смене ядра (0,009) - *ширина окна важнее выбора ядра*.




Рис. 8. При неоднородной плотности переменное окно выигрывает у фиксированного.




Рис. 9. Размах LOO-ошибки: варьирование h против варьирования ядра.

4.5 Реальные данные

На двух реальных датасетах признаки стандартизованы, ширина окна подобрана по LOO на обучающей части (табл. 2, 3). Метод даёт осмысленные R^2 (для Diabetes около 0,37); различие ядер невелико, что согласуется с выводом о вторичности ядра. Для California Housing критична стандартизация: без неё признаки большего масштаба доминировали бы в евклидовой метрике.

Таблица 2. Качество ядерной регрессии - Diabetes (MAE, RMSE в единицах целевой переменной).

ядро	h^*	MAE	RMSE	R^2
гауссовское	1.241	45.398	56.533	0.374
Епанечникова	2.959	45.082	57.016	0.363
квадратичное	3.818	45.059	56.128	0.382
треугольное	2.959	45.148	57.172	0.359

Таблица 3. Качество ядерной регрессии - California Housing (цель в единицах \$100 000).

ядро	h^*	MAE	RMSE	R^2
гауссовское	0.981	0.612	0.822	0.479
Епанечникова	1.661	0.520	0.737	0.581
квадратичное	1.661	0.500	0.722	0.599
треугольное	1.661	0.516	0.733	0.586

4.6 Подбор окна: LOO и кросс-валидация

Условие допускает подбор по LOO или по кросс-валидации; сравним оба критерия (рис. 10). Кривые ошибки близки, а оптимумы лежат в одной области: LOO даёт $h^* \approx 0,31$, 5-кратная кросс-валидация - $h^* \approx 0,23$ (меньше, так как обучается на 4/5 выборки). Оба критерия выбирают разумную ширину окна.




Рис. 10. Подбор h по LOO и 5-кратной кросс-валидации: оптимумы в одной области.

4.7 Проверка: НВ как минимум локально взвешенного МНК

Чтобы подтвердить вывод из раздела 2.3 численно, для контрольной точки $x_0 = \pi$ построен функционал $Q(\theta; x_0) = \sum_i K_i(\theta - y_i)^2$ (рис. 11). Это выпуклая квадратичная парабола по θ (коэффициент при θ^2 равен $\sum_i K_i > 0$), поэтому её единственный минимум - взвешенное среднее $\theta^* = \sum_i K_i y_i / \sum_i K_i$, то есть формула Надарая-Ватсона. Численно минимум графика совпал с этой формулой (расхождение в пределах шага сетки по θ).




Рис. 11. Парабола $Q(\theta; x_0)$ и её минимум θ^* , совпадающий с оценкой НВ.

5 Выводы

1. Реализованы «с нуля» три метрических метода: НВ с фиксированным и переменным окном и робастный LOWESS; параметры подбираются по LOO. Теоретическая основа - метрическое пространство и гипотеза непрерывности; оценка НВ выведена как решение локально взвешенного МНК.
2. На качество сильнее влияет ширина окна, чем выбор ядра (размах ошибки 0,393 против 0,009).
3. Переменное окно полезно при неоднородной плотности данных: оно расширяет окно в разреженных областях и сужает в плотных, сохраняя локальность.
4. LOWESS повышает устойчивость к выбросам (RMSE 0,096 против 0,337 при 12 % выбросов) и выигрывает у обычного сглаживания начиная с умеренного уровня загрязнения.
5. Для многомерных реальных данных принципиальна стандартизация признаков (выбор метрики).

Использование ИИ

Содержательное решение (постановка, вывод оценки НВ, реализация, интерпретация, выводы) выполнено самостоятельно. ИИ применялся для разъяснения теории, оформления и проверки вычислений. Ссылки на чаты:

Ссылка на чат	Что сделано с помощью ИИ
ссылка	общие теоретические сведения про задачу ядерной регрессии Надарая-Ватсона
ссылка	написание докстрингов для функций
ссылка	описание алгоритмов для реализации
ссылка	написание формул LaTeX
ссылка	написание кода для сохранения графиков и таблиц в формате LaTeX

Список литературы

1. А. Н. Колмогоров, С. В. Фомин. *Элементы теории функций и функционального анализа*. - М.: Наука.
2. Документация scikit-learn: датасеты Diabetes и California Housing.

Приложение. Репозиторий с кодом

Исходный код (Python-модули, воспроизводящие все вычисления, графики и таблицы) выложен в репозитории: *(вставить ссылку на репозиторий)*.